Московский государственный технический университет им. Н.Э. Баумана.

Факультет «Информатика и управление»

Кафедра ИУ5. Курс «Техно	логии машинного обучения»	
Отчет по лабораторной работе №3: «Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»		
Выполнил: студент группы ИУ5-63 Курганова Александра	Проверил: Подпись и дата:	
Подпись и дата:		

Отчет по лабораторной работе №3: "Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных".

лр3

```
In [1]:
          import numpy as np
          import pandas as pd
          pd.set option('display.max.rows', 1000)
          import seaborn as sns
          import matplotlib.pyplot as plt
          %matplotlib inline
          sns.set(style='ticks')
          data = pd.read csv('πp3.csv')
In [2]:
          data.head()
Out[2]:
                  ld source
                               latitude longitude region
                                                           country
                                                                        admin1
                                                                                       localityName localityQuality observationDate ... speciesDesci
                                                             South
                                                                       KwaZulu-
                                                                                                                                            dor
                                                                                HPAI_H5N8_2017_019
          0 230399
                        OIE -27.900000 30.800000
                                                   Africa
                                                                                                           Exact
                                                                                                                      17/08/2017 ...
                                                             Africa
                                                                          Natal
                                                                                                                                        unspecifie
                                                                       Omskaya
                                                           Russian
                             54.837037 73.354155 Europe
          1 230381
                                                                                     Novaya Stanica
                                                                                                           Exact
                                                                                                                      16/08/2017 ...
                                                                                                                                        domestic.
                                                         Federation
                                                                         Oblast
                        OIE -21.077740 30.211620
                                                                                                                      16/08/2017 ...
             230333
                                                   Africa
                                                         Zimbabwe
                                                                       Masvingo
                                                                                           Mwambe
                                                                                                           Exact
                                                                                                                                        domestic.
                                                             South
                                                                                                                                       wild, unsp
          3 230396
                        OIE -26.000000 28.300000
                                                   Africa
                                                                        Gauteng HPAI H5N8 2017 020
                                                                                                           Exact
                                                                                                                      15/08/2017 ...
                                                             Africa
                                                             Czech
             230371
                            49.237900 17.700200 Europe
                                                                   Jihomoravsky
                                                                                           Hvozdná
                                                                                                           Exact
                                                                                                                      15/08/2017 ...
                                                                                                                                         wild, wil
                                                           Republic
          5 rows × 24 columns
          data.shape
In [3]:
Out[3]: (17008, 24)
```

In [4]: data.dtypes

Out[4]:	Id	int64
	source	object
	latitude	float64
	longitude	float64
	region	object
	country	object
	admin1	object
	localityName	object
	localityQuality	object
	observationDate	object
	reportingDate	object
	status	object
	disease	object
	serotypes	object
	speciesDescription	object
	sumAtRisk	float64
	sumCases	float64
	sumDeaths	float64
	sumDestroyed	float64
	sumSlaughtered	float64
	humansGenderDesc	object
	humansAge	float64
	humansAffected	float64
	humansDeaths	float64
	dtype: object	

```
In [5]: data.isnull().sum()
Out[5]: Id
                                   0
                                   0
        source
        latitude
                                   0
        longitude
                                   0
        region
                                   0
        country
                                   0
        admin1
                                   0
        localityName
                                   0
        localityQuality
                                   0
        observationDate
                                 502
        reportingDate
                                   0
                                   0
        status
        disease
                                   0
        serotypes
                                6941
        speciesDescription
                                1648
        sumAtRisk
                                7251
        sumCases
                                2473
        sumDeaths
                                2840
        sumDestroyed
                                4003
        sumSlaughtered
                                4773
        humansGenderDesc
                               16648
                               15940
        humansAge
        humansAffected
                               15591
        humansDeaths
                               16557
        dtype: int64
```

анализ данных датасета

```
In [6]: # удаление колонок с пропусками в больше 70 процентов
        data = data.drop(columns=['humansGenderDesc', 'humansAge', 'humansAffected', 'humansDeaths'])
        data.isnull().sum()
Out[6]: Id
                                  0
        source
        latitude
        longitude
        region
        country
        admin1
        localityName
        localityQuality
        observationDate
                                502
        reportingDate
                                  0
        status
        disease
                                  0
        serotypes
                               6941
        speciesDescription
                               1648
        sumAtRisk
                               7251
        sumCases
                               2473
        sumDeaths
                               2840
        sumDestroyed
                               4003
        sumSlaughtered
                               4773
        dtype: int64
In [7]: # нахождение колонок с нулевыми значениями
        colnull = []
        for col in data.columns:
            null count = data[col].isnull().sum()
             if data[col].dtype in ('float64', 'int64') and null count != 0:
                 colnull.append(col)
        print('колонки с нулевыми значениями:', colnull)
        колонки с нулевыми значениями: ['sumAtRisk', 'sumCases', 'sumDeaths', 'sumDestroyed', 'sumSlaughtered']
In [8]: from sklearn.impute import SimpleImputer
        from sklearn.impute import MissingIndicator
```

```
In [9]: # заполнение пустых числовых колонок с помощью медианы
         for col in colnull:
             i = MissingIndicator()
             miss = i.fit transform(data[[col]])
             med = SimpleImputer(strategy='median')
             data[[col]] = med.fit transform(data[[col]])
In [10]: data.isnull().sum()
Out[10]: Id
                                   0
         source
         latitude
         longitude
         region
         country
         admin1
         localityName
         localityQuality
         observationDate
                                 502
         reportingDate
                                   0
         status
         disease
                                6941
         serotypes
         speciesDescription
                                1648
         sumAtRisk
         sumCases
                                   0
         sumDeaths
         sumDestroyed
         sumSlaughtered
         dtype: int64
```

```
In [11]: # удаление ненужных для анализа категориальных колонок
data = data.drop(columns=['observationDate', 'reportingDate', 'speciesDescription'])
# заполнение пустых значений в категориальных данных
cat_colnull = []
for col in data.columns:
    null_count = data[col].isnull().sum()
    if data[col].dtype not in ('float64', 'int64') and null_count != 0:
        cat_colnull.append(col)

print('категориальные колонки с нулевыми значениями:', cat_colnull)
```

лр3

категориальные колонки с нулевыми значениями: ['serotypes']

```
In [12]: # заполнение пустых значений в категориальных колонках с помощью моды

for col in cat_colnull:
    i = MissingIndicator()
    miss = i.fit_transform(data[[col]])
    mod = SimpleImputer(strategy='most_frequent')
    data[[col]] = mod.fit_transform(data[[col]])
```

```
In [13]: data.isnull().sum()
Out[13]: Id
                             0
         source
                             0
         latitude
                             0
         longitude
                             0
         region
                             0
         country
                             0
         admin1
                             0
         localityName
                             0
         localityQuality
                             0
         status
                             0
         disease
                             0
         serotypes
                             0
         sumAtRisk
                             0
         sumCases
                             0
         sumDeaths
                             0
         sumDestroyed
                             0
         sumSlaughtered
                             0
         dtype: int64
```

преобразование категориальных признаков в числовые

```
In [14]: cat coll = []
         for col in data.columns:
             if data[col].dtype == 'object':
                 cat coll.append(col)
         for col in cat coll:
             print(col, len(data[col].unique()))
         source 12
         region 4
         country 122
         admin1 941
         localityName 9279
         localityQuality 5
         status 2
         disease 26
         serotypes 60
In [15]: from sklearn.preprocessing import LabelEncoder
```

```
In [16]: # использование готового класса для кодирования
en_cat = {}
for col in cat_coll:
    le = LabelEncoder()
    # заполнение и преобразование
    data[[col]] = le.fit_transform(data[col])
    print(col, data[col].unique())
    en_cat[col] = le
```

лр3


25 3 2 22 31 37 34 33 29 30 19 231

```
449 257 48 536 231 403 510 445 812 333 866 386 315 235 16 95 527 938
 383 690 440 837 398 116 233 0 535 469 225 702 684 88 508 548 854 107
 591 832 132 163 582 927 804 887 43 643 520 662 182 797 464 515 563 290
 592 274 247 650 465 803 256 841 170 787 785 148 734 57 203 476 670 158
 249 633 454 60 119 410 693 280 864 885 669 738 135 234 41 820 370 91
 746 621 642 916 618 801 441 179 299 75 140 439 177 369 886 300 112 400
 625 354 623 711 505 919 189 541 598 846 722 473 24 506 120 606 40 357
 424 335 509 853 109 914 735 86 243 636 361 768 609 835 639 692 617 566
 395 547 730 94 325 806 614 5 269 923 206 898 58 190 603 597 328 528
 579 783 313 718 608 641 867 242 818 210 644 793 425 377 434 747 455 415
 31 488 890 409 770 70 44 848 421 878 90 663 775 891
                                                          9 790 181 362
 102 778 433 253 933 81 855 557 366 655 502 647 601 699 568 870 679 857
 27 458 63 859 178 467 875 241 856 668 894 347 289 463 807 139 113 446
 651 573 348 652 675 724 349 310 413 588 928 926 15 344 811 556 757 273
 584 533 85 839 336 327 380 215 340 212 254 495 240 661 653 387 312 65
 183 219 847 404 842 762 437 714 17 42 220 171 522 795 656 108 51 202
 435 755 72 736 142 546 200 838 61 29 899 574 265 92 777 69 46 103
 819 426 800 521 907 74 483 861 428
                                      4 399 700 761 381 649 21 481 543
114 810 131 364 531 168 715 389 264 151 180 555 612 622 739 798 160 128
 682 620 137 683 858 780 100 565 550 786 490 138 704 688 263 501 707 223
 489 600 687 705 5941
localityName [2997 5577 5301 ... 5823 5694 2015]
localityQuality [3 2 0 4 1]
status [0 1]
disease [14  1 12 19 15 17 25 18 11 22 23  0  4 24  2 21 20  3 10  7  8  5  9 16
 6 131
serotypes [36 11 14 17 15 21 57 52 55 8 38 51 26 7 9 42 27 10 58 53 54 45 24 28
 20 40 47 39 12 41 46 44 56 6 43 49 16 48 0 5 4 50 59 35 13 1 18 32
```


```
In [17]: data.dtypes
Out[17]: Id
                               int.64
                               int64
         source
         latitude
                             float64
         longitude
                             float64
         region
                               int64
         country
                               int64
         admin1
                               int64
         localityName
                               int64
         localityQuality
                               int64
         status
                               int64
         disease
                               int64
                               int64
         serotypes
         sumAtRisk
                             float64
                             float64
         sumCases
         sumDeaths
                             float64
         sumDestroyed
                             float64
         sumSlaughtered
                             float64
         dtype: object
In [18]:
         # выполнение декодирования
         en_cat
Out[18]: {'source': LabelEncoder(),
           'region': LabelEncoder(),
           'country': LabelEncoder(),
           'admin1': LabelEncoder(),
           'localityName': LabelEncoder(),
           'localityQuality': LabelEncoder(),
           'status': LabelEncoder(),
           'disease': LabelEncoder(),
           'serotypes': LabelEncoder()}
In [19]: en_cat['region'].inverse_transform([0, 3, 2, 1])
Out[19]: array(['Africa', 'Europe', 'Asia', 'Americas'], dtype=object)
```

масштабирование

```
In [21]: from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
In [22]: sc1 = MinMaxScaler()
    sc1_data = sc1.fit_transform(data[['sumAtRisk']])
In [40]: plt.hist(data['sumAtRisk'], 50, range=[0, 2500])
    plt.show()
```




```
In [43]: plt.hist(sc1_data, 50, range=[0, 0.00125])
   plt.show()
```



```
In [59]: # на основе z-оценки
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['sumAtRisk']])
```

```
In [60]: plt.hist(sc2_data, 50, range=[0, 10])
    plt.show()
```



```
In [61]: # нормализация
sc3 = Normalizer()
sc3_data = sc3.fit_transform(data[['sumAtRisk']])
plt.hist(sc3_data, 50)
plt.show()
```

